序論

脳は外界からの膨大な感覚入力を効率的に処理し、学習・認知・意思決定を可能にする高度な情報処理システムである。この生物学的情報処理の仕組みに着想を得て、人工ニューラルネットワーク（Artificial Neural Network、 ANN）が提案されてきた。近年では、深層学習の発展により、ANN は画像認識、自然言語処理、強化学習など多様な分野で顕著な成果を挙げている。現在用いられているモダンな ANN のほとんどは、誤差逆伝播（Backpropagation、 BP）に基づく勾配降下法を前提としており、高精度な表現学習を実現している。しかし、BP は学習時に Feedforward(FF)と Feedback(FB)の厳密な同期を要求するため、計算の並列化を阻害する問題を抱えている。さらに、全層の誤差情報を保持・伝播するための膨大なメモリ消費や消費電力は、次世代の省電力ハードウェア実装における大きな障壁となっている。一方で、実際の脳神経回路は、BP において本質的に要求される ~~Feedforward(~~FF~~)~~と ~~Feedback(~~FB~~)~~の厳密な分離や、それに伴う重み行列の対称性を仮定することなく、局所的かつ非同期的な情報処理が可能で、効率的かつ安定した学習を実現している。このように実際の脳というものは、対称性を仮定しない重み行列を、さらに複数の異なる学習で使いまわし、リアルタイムで重みが変更されていく状況でもなお、重み崩壊を引き起こすことなく、安定した学習が可能である非常に頑健なネットワークである。つまり、脳が BP とは本質的に異なる計算原理に基づいて学習している可能性が示唆される。したがって、脳神経回路の制約と整合的でありながら、高い学習性能を実現する生物学的に妥当な学習アルゴリズムを明らかにすることは、神経科学的理解の深化のみならず、次世代の ANN 設計にとっても重要な課題である。

生物学的にあり得ない操作の一つである、非同期処理を回避するパラダイムの候補として注目されているのが、脳の知覚・学習をベイズ推論的に説明する予測符号化（Predictive Coding、 PC）である。PC は、各ニューロンあるいは局所回路が、自身に入力される信号と局所的に生成される予測との誤差のみを用いて活動を更新できる点に特徴があり、誤差の大域的な逆伝播や厳密な時間的同期を必要としない学習原理として、生物学的妥当性が高いと考えられている。PC の代表的モデルの一つとして、Rao らが視覚野の神経活動を説明する枠組みを提案した[1]。その後、この理論は Friston による自由エネルギー原理[2], [3], [4]や、Bastos らによる視覚皮質における階層的予測符号化の神経回路モデル[5]などに発展し、知覚・学習・行動を統合的に説明する理論として広く支持されている。本研究はそれらの中から、PC を教師あり学習に拡張した Whittington のモデルをベースに議論を進めていく[6]。PC の活動更新およびシナプス可塑性は、隣接する階層間の信号と予測誤差に基づく局所的な計算として記述でき、BP のような大域的な誤差信号の伝播を仮定しない。さらに、この階層間の反復的な処理(双方向ループ)は実際の神経回路に見られる再帰結合と対応しており、予測符号化は従来の深層学習モデルに比べて生物学的妥当性の高い

Commented [広兼浩二朗1]: BP の代替手法を提案する動機が”生物学的に妥当じゃない”だけだとやっぱり弱すぎる気がしたので、工学的な理由も足してみた。

情報処理モデルであると考えられている。

しかしながら、PCや関連する学習モデルがすべての問題を解決したわけではない。BPにおける生物学的にあり得ない操作の二つ目の課題である、フィードバック（FB）接続にフィードフォワード（FF）重みの転置が与えられる、重み転置問題（weight transport problem）はPCにおいてもいまだに抱えている。この問題はさらに以下の二つに大別される。

1. 物理的に離れたFB・FF結合が同期して更新される必要がある。（重み同期問題）
2. 解剖学的に、FF 経路と FB 経路において神経細胞が必ずモノシナプティックな双方向性結合を持つことは確認されていない。（モノシナプティック双方向性結合問題）

この一つ目の課題である、「物理的に離れた FB・FF 結合が同期して更新される必要がある」という問題を克服する試みとして、一部の理論神経科学者は Hebb 則に基づき、FF 経路と FB 経路の双方の結合を学習させるモデルを提案している[6]。しかしながら、これらの提案は主に理論的枠組みに留まっており、Hebbian 学習に基づいて FB 重みを更新した場合に予測符号化がどの程度有効に機能するかについて、系統的な検証は行われていない。ここで、本研究では FF と FB が独立した Hebb 則に従う更新則を持つモデル Predictive Coding with Dual Hebb(Dual Hebb モデル)を提案し、重みの初期値を転置行列として明示的に設定せずとも、学習を通して自己組織的に相互結合の重みが転置に収束していく現象を示す。

また、二つ目の課題である、「解剖学的に、FF 経路と FB 経路において神経細胞が必ずモノシナプティックな双方向性結合を持つわけではない」という問題は、BP のみならず、PC においても有効な解決策は提案されていない。予測符号化では FF 結合と FB 結合が厳密に転置関係にある、つまり、全ての細胞ペアは双方向性結合を有するが、実際の大脳皮質において、このような回路は見いだされていない。実際の脳内で観察されるループ回路は、結合方向、細胞型、神経伝達物質の種類に応じて可塑性の性質や強度が大きく異なると考えられているため[7]、双方向性結合を前提としないネットワークで学習可能なものを考える必要がある。ここで、本研究では新たに、FB 重みとしてランダム行列を採用した Predictive Coding with Loop Alignment(LA モデル)を提案した。このネットワークを用い、複数タスクにおいて異なるネットワーク間で重みが共有される場合や、FB重みに動的なノイズを乗せた際の挙動を調べることで、重み転置問題における二つの問題を排除した状態でも、重み崩壊などを引き起こさず学習可能であることを示した。同時に本モデルのロバストさについても定量的な評価を行った。

Model Overview

本研究では、baseline model として教師あり学習に拡張した PC モデルを実装した[6]。このモデルは各階層iにおいて、神経細胞の活動量（x_i）、対応するエラー神経細胞の活動量（ε_i）、神経細胞とエラー神経細胞との間の結合重み（W_i）を持つ。同階層における表現ニューロンからエラーニューロンへの接続方向をフィードフォワード(FF)、その逆方向をフィードバック(FB)とすると、エラーニューロン（ε_i）、表現ニューロン(x_i)と重み(W_i^{FF}, W_i^{FB})の更新は以下の式 1-3 で表される。

$$\varepsilon_i = x_{i+1} - x_i W_i^{FF} \tag{1}$$

$$\Delta \mathrm{x_i} = -\varepsilon_{i-1} + \varepsilon_i W_i^{FB} \tag{2}$$

$$\Delta W_i^{FF} = x_i \varepsilon_i^T \quad (W_i^{FB} = (W_i^{FF})^T) \tag{3}$$

このモデルにおいては表現ニューロンとエラーニューロン間のフィードバック結合は重みの転置行列を用いている($W_i^{FB} = W_i^{FF}$; Fig. 1A~~Figure 1A~~)。Baseline Model に関して、以後のモデルとの比較を簡素化するため、活性化関数とオプティマイザは実装していない。

続いて、従来手法で採用されてきた「FB 重みを単純に FF 重みの転置として設定する」という制約を回避するため、Hebbian 学習則に基づき FF・FB 双方の経路を独立に学習可能な予測符号化モデルとして、Dual Hebb モデル（Predictive Coding with Dual Hebb）を設計した（Error! Reference source not found.~~図 1~~B)。Dual Hebb モデルでは、FF 経路で獲得されたシナプス重み情報をそのまま FB 経路の重みとして用いる転置操作は行わず、FB 経路の重みはε_iとx_iの細胞群間における Hebb 則に基づいて、FF 経路とは独立に学習される。

本モデルでは、まずエラーニューロン（ε_i）と表現ニューロン(x_i)の活動が更新され、その更新式は baseline モデルと同様に~~式 1, 2 で~~与えられる(式 1, 2)。続いて、更新された x_i の活動に基づき、FF・FB 双方のシナプス重みが Hebb 則に従って更新される(式 4, 5)。~~その更新則はそれぞれ式 4 および式 5 で表される。~~なお、エラー神経細胞の活動量の計算については、baseline model と同様の処理を行うものとする。

$$\Delta W_i^{FF} = x_i \varepsilon_i^T \tag{4}$$

$$\Delta W_i^{FB} = \varepsilon_i x_i^T \tag{5}$$

Commented [広兼浩二朗2]: このハイパーリンクみたいなやつ消してくれ。

Commented [広兼浩二朗3]: 式 1 で計算されると言ってるからこの文は冗長？いらないよな？

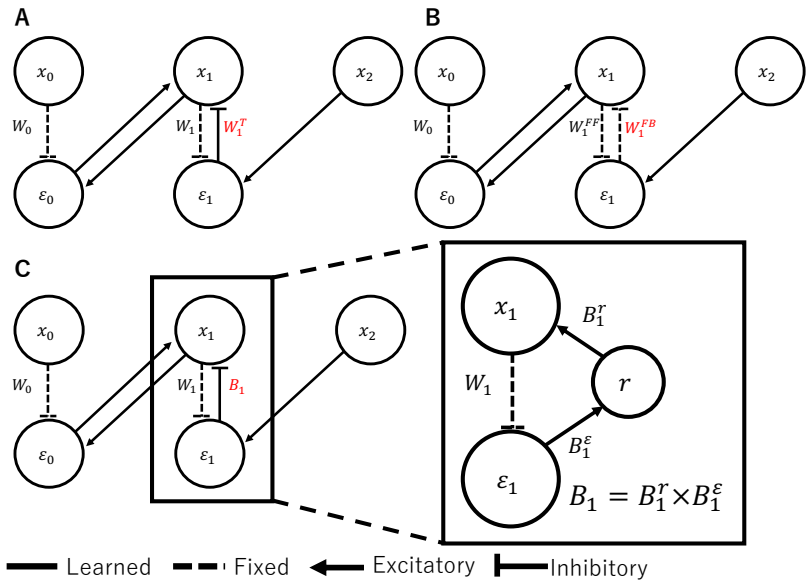

Figure 1:本実験で用いる予測符号化モデルの概形

丸で示すノードは神経核を表し，x は表現ニューロン，ε はエラーニューロン。学習可能な重みと学習しない固定重みを区別するため、前者を点線、後者を実線で示した。
(A) **転置モデルの概形**：転置モデルでは，フィードバック重みに順方向重みの転置を用いた。(B) **Dual Hebb モデルの概形**：順方向重みおよびフィードバック重みは，それぞれ独立した Hebb 則に従って更新される。(C) **LA モデル**：(左) モデルの概形。フィードバック重みにランダム重みを設定する。(右) 表現ニューロン x とエラーニューロン ε 間の経路に中継核 r（relay nucleus）を含み、$\varepsilon - r$ 間の重みをランダム行列 B_1^r、$\varepsilon - x$ 間の重みをランダム行列 B_1^ε とした場合を考える。このとき、表現ニューロンとエラーニューロン間の有効結合は、B_1^ε と B_1^r の積として表され、この積もまたランダム行列となる。

結果

Dual Hebb モデルは予測符号化 baseline model と同等の精度を達成した

Dual Hebb モデルの有効性を検証するため、MNIST 分類タスクを用いた実験を行った。まず、Dual Hebb モデルにおいて学習が収束可能であるか、すなわち baseline model と同様にエネルギー（エラー細胞の活動量総和；Methods の式 18~~12~~ を参照）の最小化が実現されるかを検証するため、MNIST 分類タスクにおける学習過程のエネルギー推移を記録した。baseline model と同様に、Dual Hebb モデルでは学習の進行に伴いエネルギーが全ステップにわたって単調に減少することが確認された（Figure 2~~Figure 2~~-A)。これは、FB 重みが局所的な Hebb 則によって FF 重みとは独立に更新されていく場合であっても、予測符号化に基づくエネルギー最小化が安定に達成されることを示している。

次に、MNIST 画像分類精度について評価を行った結果、Dual Hebb モデルは最終的に約 85%の精度に到達した（Figure 2~~Figure 2~~-B)。これは Baseline モデルとほぼ同じ水準であ

Commented [広兼浩二朗4]: 点線と実線が、図では逆になってる。

Commented [広兼浩二朗5]: 他の場所でも言ったけど、この推論はランク落ちを議論してないので個人的には危険。
なんでこれを言いたいのかを考えて、「複数の神経核を経由した複雑な挙動をモデルに組み込むために FB をランダム行列として実装した」くらいでもいいのかどうかを考えてほしい。

Commented [上6R5]: 変更後の文章で、、ランダム行列がモデル拡張の可能性があるというニュアンスになっていますか？
また、これはキャプションより本文の方がいいですか？

Commented [広兼浩二朗7R5]: こっちの方がいいね。内容的には Result の中に入れるべきやから入れといた

った。

さらに、Dual Hebb モデルにおいて、FF 重みと FB 重みが転置関係へと収束するかを検証するため、両者のコサイン類似度を測定した。FF・FB 重みはランダム行列で初期化されているため、学習初期におけるコサイン類似度はほぼ 0 であり、両者は無相関な関係にある。しかし、学習の進行に伴ってコサイン類似度は単調に上昇し、最終的には 1 に近い値へと収束した（Figure 2~~Figure 2~~C）。これは、局所的な Hebb 学習則のみに基づいて FF・FB 重みが自発的に転置関係を形成することを示している。

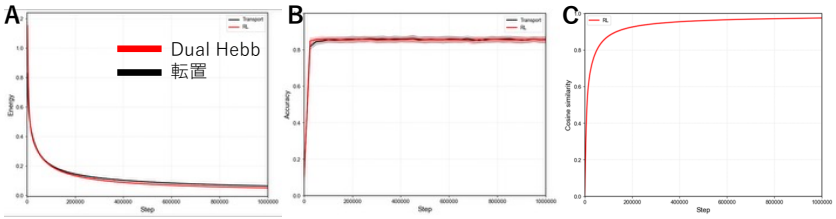

Figure 2:Dual Hebb モデル検証

Dual Hebb モデルおよび転置モデルの構造および MNIST 分類タスクにおける学習挙動を示す。図 B~E の赤線は Dual Hebb モデル、黒線は Baseline モデルを表す。実線は 10^6 iterations を 1 session とし 50 session の平均値、陰影は標準偏差（±1 SD）を示す。

A)**エネルギーの推移：**縦軸は Dual Hebb モデル(赤)と Baseline の PC (黒)の学習時におけるエネルギー、横軸は iteration を示す。

B) **MNIST 分類タスクの精度推移**：縦軸は Dual Hebb (赤)と一般的な転置を用いる PC(赤)の分類精度、横軸は iteration を示す

C)**コサイン類似度の推移：**縦軸は Dual Hebb モデルにおける FF 重み及び FB 重みベクトル間のコサイン類似度、横軸は学習 iteration 数を示す。W_1^{FF}は 100×10 の行列、W_1^{FB} は 10×100 の行列として定義されている。両者の要素ごとの比較を可能にするため、コサイン類似度の計算では W_1^{FF} を転置した行列 $(W_1^{FF})^T$ を用い、$vec(W_1^{FF})$ と $vec((W_1^{FF})^T)$ の間のコサイン類似度を算出した。

これにより、Dual Hebb モデルは、先に述べた重み同期問題を解決することが可能である。

図 2 C で示したように、Dual Hebb モデルでは FF・FB 重み間のコサイン類似度が最終的に 1 に収束する。W_i^{FF}とW_i^{FB}の初期値を、それぞれ$init_i^{FF}$・$init_i^{FB}$とすると、式 6、式 7Error! Reference source not found.が成り立つ。式 8 より、iteration が十分大きく、$init_i^{FF}$・$init_i^{FB}$が相対的に十分小さいとみなせる場合には、W_i^{FF}とW_i^{FB}は転置行列に近づいていくことがわかる。

$$W_i^{FF} = init_i^{FF} + \alpha_x \sum^{step} x_i^T \varepsilon_i \tag{6}$$

$$W_i^{FB} = init_i^{FB} + \alpha_x \sum^{step} \varepsilon_i^T x_i \tag{7}$$

$$\sum^{step} x_i^T \varepsilon_i = \left(\sum^{step} \varepsilon_i^T x_i \right)^{\boldsymbol{T}} \tag{8}$$

LA モデル

Dual Hebb モデルは、FF および FB 経路に対して対称的な学習則を導入することで、重み転置問題の一部である重み同期問題に対して有効であることを示した。一方で、このモデルでは、単一シナプスの双方向性結合を仮定しており、学習則の成立には回路構造に強い制約が課される。実際の脳内回路では、FF および FB 経路が単一のシナプス対によって直接結合されるとは限らず、3 つ以上の神経核から構成されるループ構造が一般的であることが知られている[8]。このような構造においては、FF および FB 結合が必ずしも完全に同じ細胞を共有するとは限らず、学習則の対称性を前提としたモデルの適用は困難となる。

そこで本研究では、Backpropagation において提案された Feedback Alignment の考え方を予測符号化に応用し、FB 経路が学習されない固定のランダム行列によって実装される Loop Alignment（LA）モデルを採用する(Fig. 1C)。すなわち、複数の神経核を経由する FB 経路における複雑な信号伝達を単純化して表現するための簡略化として、FB 重みをランダム行列として実装した。この場合 ~~LA モデルでは~~、FB 重みは FF 重みと対応するシナプス対を持たず、誤差信号を伝播させるための回路としてのみ機能する。このため、学習則の対称性に依存した重みの対応関係は要求されず、FF 側の局所的な学習が F B の重みと完全に切り離された状態で学習が進行する。

Error! Reference source not found.~~図 1~~-C に、FB 重みを固定のランダム行列としたネットワークを示す。エラーニューロンおよび FF 重みの更新則は baseline model と同様であり、Layer i における FB のランダム重み行列を Bi とすると表現ニューロンの更新式は以下のように表される。

$$\Delta \mathrm{x_i} = -\varepsilon_{i-1} + \varepsilon_i \mathrm{B_i} \tag{9}$$

まず、LA モデルがエネルギー最小化を学習可能であるかを検証するため、MNIST 分類タスクにおける学習過程のエネルギー推移を記録した。その結果、LA モデルにおいてもエネルギーが単調に減少・収束することが確認された（Figure 3~~Figure 3~~-A）。

次に、MNIST 画像分類精度について評価を行った。LA モデルは学習の進行とともに分類精度が向上し、最終的に約 85%の精度に到達した（Figure 3~~Figure 3~~-B）。この最終的な分類性能は baseline model および Dual Hebb モデルと同程度であり、FB 重みが学習されないという制約にもかかわらず、LA モデルが十分な分類能力を獲得可能であることを示している。

さらに、LA モデルにおいて、FF 重みと FB 重みの関係性を定量的に評価するため、両者のコサイン類似度を測定した。LA モデルでは FB 重みを固定ランダム行列として用いているため、理論的には FF・FB 重みが転置関係へと収束することは想定されていない。実際、学習初期におけるコサイン類似度はほぼ 0 であり、FF 重みと FB 重みは無相関な関係にあ

る。しかし、学習の進行に伴ってコサイン類似度は徐々に上昇し、最終的にはおよそ 0.9 と高い相関関係に収束することが観測された（Figure 3~~Figure 3~~-C）。

この結果は、LA モデルにおいて、FB 重みが固定であるにもかかわらず、FF 重みが学習を通じて FB 重みと整合的な構造を獲得していることを示唆している。すなわち、誤差伝播経路として形成されるループ全体のダイナミクスを通じて、FF 重みが FB 重みの構造に適応する現象が生じていると考えられる。本研究ではこの現象を Loop Alignment（LA）と呼ぶ。

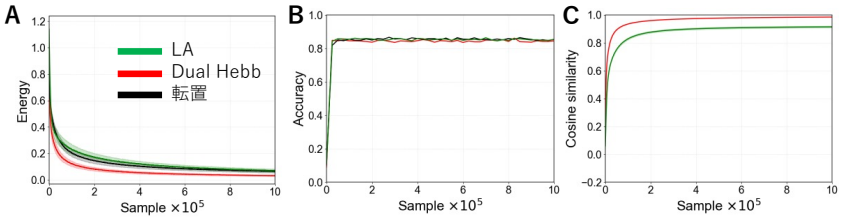

Figure 3: LA モデル検証

LA モデル、Dual Hebb モデルおよび転置モデルの構造および MNIST 分類タスクにおける学習挙動を示す。緑線は LA モデル、赤線は Dual Hebb モデル、黒線は Baseline モデルを表す。実線は 10^6 iteration を 1 session とし 50 session の平均値、陰影は標準偏差（±1 SD）を示す。

A)**エネルギーの推移**：縦軸は LA モデル(緑)、Dual Hebb モデル(赤)および Baseline モデル（黒）のエネルギー、横軸は iteration 数を示す。

B)**MNIST 分類タスクにおける精度推移**：縦軸は LA モデル(緑)、Dual Hebb モデル(赤)および Baseline モデル（黒）の MNIST 画像分類精度、横軸は iteration 数を示す。

C)**コサイン類似度の推移：**縦軸は LA モデル(緑)および Dual Hebb モデル(赤)における FF 重み及び FB 重みベクトル間のコサイン類似度、横軸は iteration 数を示す。

以上の結果から、LA モデルの学習には、FF・FB 重みの転置関係や厳密かつ大域的な誤差情報の伝播を必要としないことが示されたを明示的に仮定しない条件下においても、エネルギー最小化および高い分類性能を安定に実現可能であることが示された。またさらに、Loop Alignment の観測は、誤差信号のループ構造を通じた反復的な伝播と局所的な Hebb 則によって生まれる、自己組織的な現象である。誤差伝播が厳密な勾配情報を含まない場合であっても、ネットワーク全体のループ構造を通じて有効な学習が成立し得ることを示唆している。

LA 動作原理・命名理由

LA モデルにおいて FF 重みが固定ランダム行列 B に整列していく現象は、推論ダイナミクスと Hebbian 学習の相互作用による重みのドリフトとして理解できる。表現ニューロン x_i の更新規則、および FF 重みの更新則を以下のように定義する。まず LA における表現ニューロンと重みの学習則を書き出すと以下のようになる。

$$x_i \leftarrow x_i + \eta \left(\varepsilon_{i-1} - \alpha \mathrm{B_i} \varepsilon_i\right) \tag{10}$$

$$\Delta \mathrm{W^{FF}} = \varepsilon_i x_i^T \tag{11}$$

(11)を(12)に代入し、展開すると以下の関係が得られる。

$$\begin{aligned}\Delta \mathrm{W^{FF}} &= (x_i - \eta\varepsilon_{i-1} + \alpha\eta B_i \varepsilon_i)\varepsilon_i^T \\ &= x_i\varepsilon_i^T - \eta\varepsilon_{i-1}\varepsilon_i^T + \alpha\eta B_i \varepsilon_i \varepsilon_i^T \\ &= x_i\varepsilon_i^T - \eta\varepsilon_{i-1}\varepsilon_i^T + \alpha\eta B_i\left(\varepsilon_i\varepsilon_i^T\right)\end{aligned} \tag{12}$$

ここで、エラーの自己相関行列 $\varepsilon_i\varepsilon_i^{\mathrm{T}}$ について、学習が進みエラー信号自体がホワイトノイズ化した定常状態を仮定して、その期待値を $\mathrm{E}[\varepsilon_i\varepsilon_i^{\mathrm{T}}] = \sigma_\varepsilon^2$ と置くと、重み更新の期待値は以下のようになる。

$$\Delta \mathrm{W^{FF}} = x_i\varepsilon_i^T - \eta\varepsilon_{i-1}\varepsilon_i^T + \alpha\eta\sigma_\varepsilon^2 \mathrm{B_i} \tag{13}$$

よって、第三項の寄与により $\mathrm{W^{FF}}$ は最終的には $\mathrm{B^T}$ の方向にドリフトしていくことがわかる。我々はこの予測を検証するため、学習過程におけるエラー自己相関行列の推移を計測した。結果として、学習初期に存在した強い非対角成分（エラーニューロン間の相関）は学習の進行に伴って急速に減衰し(Fig. 3D)、十分な学習後においては対角行列($\sigma_\varepsilon^2\mathrm{I}$)で近似できることが実験的に確認された。

従って、ループ回数を増加させることにより、エラーニューロンの活動がランダム行列を通して表現ニューロンに伝播される回数が増加し、より多くのランダム行列 B の情報が FF 重みに取り込まれると考えられる。これを検証するため、LA モデルにおける表現ニューロンとエラーニューロン間での反復処理回数（Loop 回数）を変化させて、その際の FF-FB 重み間のコサイン類似度の推移を計測した。具体的に、表現ニューロンの更新を行う反復処理回数を 1 回、2 回、5 回、10 回の 4 条件に段階的に設定し、それぞれの条件下において FF・FB 重み間のコサイン類似度を評価した。結果、すべての条件において学

Commented [広兼浩二朗8]: ちなみにこれも示してグラフにして Figure3D に足したいね、余裕があれば。
この一連の説明の後に、”実際、学習を通してエラーニューロンの活動はホワイトノイズ様の振る舞いに近づいていく”的な一文があると良きかも。

Commented [広兼浩二朗9]: あってる？
上の定性的な文章なら書かないほうがいいかも。これであってるならこれに差し替えよう。
ただそうすると、結局 Dual にしろ LA にしろ、WFF に WFB の転置成分が漏れ出してるという構図は全く一緒なので、二つのモデルの本質的な違いを、もうちょっと別の言葉で書かないといけない気がする。

Commented [上10R9]: あってる？
上の定性的な文章なら書かないほうがいいかも。これであってるならこれに差し替えよう。
>式はおそらく合っています。Gemini の思考モードでも合っているとのことでした。

Commented [上11R9]: ただそうすると、結局 Dual にしろ LA にしろ、WFF に WFB の転置成分が漏れ出してるという構図は全く一緒なので、二つのモデルの本質的な違いを、もうちょっと別の言葉で書かないといけない気がする。

>ランダムを使うことで σ_ε が大きくなりランダム行列の情報が漏れ出し、一方転置や Dual Hebb の場合は σ_ε が小さいの(転置は 0、Dual は限りなく小さい)で LA 特有の現象と言っていいのではないでしょうか。

Commented [広兼浩二朗12R9]: 双方向性結合を持つ回路か持たない回路の違いということで理解したわ。

習が進むにつれて FF 重みと FB 重みの間にアライメントが生じたが、ループ回数が多いほどアライメントの進行速度が速くなることが示された(Fig. 3E~~Figure 4-B~~)。

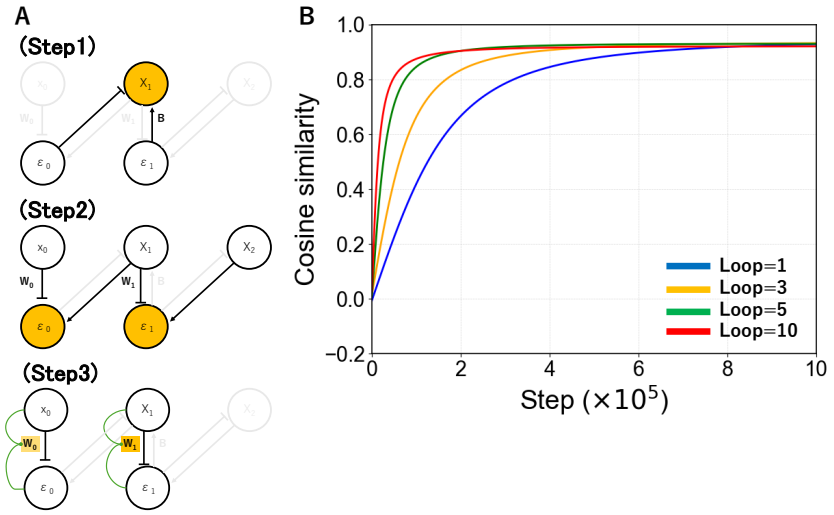

Figure 4;Loop Alignment 機序

LA モデルで観察され、 Loop Alignment と名付けた現象が、どのような原理で生じるのかについて、直感的な理解とそれを支持する実験結果を示す。

Loop Alignment の機序：Loop Alignment は、以下の 3 段階から構成されると考えられる。橙色でハイライトした神経核は、ランダム行列 B の情報を含む神経核を表す。(Step 1) 表現ニューロンは、高次のエラーニューロンからランダム行列 B を適用した信号を用いて更新される。(Step 2) エラーニューロンは、Step 1 で計算されたランダム行列 B の情報を含む表現ニューロンからの投射を受ける。(Step 3) Step 1・2 によりランダム行列 B の情報を含む表現・エラーニューロンを用い、Hebb 則に基づいて FF 重みを更新する。

Loop 回数によるコサイン類似度推移の変化：縦軸は、表現ニューロンの更新に用いる Loop 回数を変化させた際の LA モデルにおける FF 重みと FB 重みのベクトル間のコサイン類似度を示す。横軸は学習 1session 数を表す。青線は 1 回、橙線は 3 回、緑線は 5 回、赤線は 10 回の Loop を表す。実線は 1session10^6 Iteration とした 50session の平均値、陰影は標準偏差（±1 SD）を示す。

この結果から、LA モデルにおいて FF 重みがランダムに固定された FB 重みへ自発的にアライメントする現象が、誤差信号の反復伝播を通じた局所的学習則によって駆動されること示唆される。

Commented [広兼浩二朗13]: てかこの Figure 必要？Fig.4A はもはやどこでも引かれてないし、Fig.4B も Fig.3 にまとめればいいんじゃないの？

上で言ったノイズの振る舞いを Fig.3D にして Fig.4B を Fig.3E にすればいいのでは。

LA 回路共有モデル

実際の脳神経回路において、特定の経路が単一の機能だけに専有されることは稀であり多くの神経核は複数の回路の一部として機能共有されている[9]。従来の LA モデルでは FB 重み B を静的なランダム行列と仮定したが、実際の脳内では、その FB 経路自体も他の回路の FF 経路として別の学習（シナプス可塑性）の影響を受け、動的に変化していると考えられる。 よって次に、FB 経路が他の学習回路と共有され、常に変動・干渉を受ける環境下においても、LA のメカニズムが維持されるかを検証する。

そこで、2 つの独立した LA ネットワーク（Net1, Net2）を用意し、互いの FB 回路の途中に相手の FF 回路が組み込まれるように回路を配置することで、LA 回路共有モデルを構築した(~~Figure 5~~Fig. 4A)。この回路はつまり、前章まで B としてランダム行列になっていた FB 回路が、もう一つのネットワークの FF 回路をランダム行列で挟むことによって（$\mathrm{BW}_1^{\text{もう一つのネットワーク}}B$）代替されるということである。この場合の FB の挙動は、ランダム行列をベースとして、自身のネットワークとは異なるダイナミクスで、徐々に更新されていくような FB 重みとなっている。

つまり、Net1 におけるエラーニューロン、表現ニューロン、重みの更新式は以下の通りとなる。

ランダム行列は全て B とする
E x 間の重み、Ex 間の重みは B である

$$\varepsilon_i = x_2^{Net1} - W_1^{Net1} x_1^{Net1} \tag{14}$$

$$\Delta x_i = -\varepsilon_{i-1}^{Net1} + \varepsilon_i^{Net1} \mathrm{BW}_1^{\mathrm{Net2}} B \tag{15}$$

$$\Delta W_i = x_{\mathrm{i}}^{\mathrm{Net1}} \varepsilon_i^T \tag{16}$$

まず初めに、このモデルの学習時における Net1 の FB 重みの時間的構造変化（Net2 の FF 重み）および、その逆方向の影響が存在する条件下でも学習が可能であるかを検証するため、Net1 と Net2 を同一の学習条件下で並行して学習させた。具体的には、各学習ステップにおいて、一方のネットワークに対して 20 枚の画像からなるミニバッチを入力して重み更新を行った後、もう一方のネットワークに対しても同様に 20 枚の画像からなるミニバッチを入力して重み更新を行う操作を交互に繰り返した。

学習の結果、まず重みは他のモデルと同様に初期値からは十分離れていくことが確認された(Fig. 4B)。そして、FB 重みが他方の学習系による時間的構造変化の影響を受けている

Commented [広兼浩二朗14]: これは？

Commented [広兼浩二朗15]: 20 枚のバッチ処理はしてないってことで OK?

Commented [上16R15]: バッチ処理はしています。そのため、表現を変更しておきます。

Commented [広兼浩二朗17]: これは、回路を共有しないモデルだと怒らない現象？何を比べようとしてるか不明。回路を共有しなくても初期値からは離れていきそうだけど。

Commented [上18R17]: これは固定ランダム重みを用いる LA モデルと比較するために、目的関数と関係のないランダムダイナミクスがどれだけ生じたかを示すことを目的にしています。これを示すことで、Net2 学習する時の重みの動的変化量が net1 に比べてかなり小さいのではないかという疑問に対してあらかじめ対処しています。
ご指摘のとおり、baseline model でも、Dual Hebb モデルもで初期値からは乖離はします。

Commented [広兼浩二朗19R17]: なんでこの実験で""目的関数と関係のないランダムダイナミクスがどれだけ生じたかを示す""ことができてるのかが全くわからないから説明してほしい。

Commented [上20R17]: ご指摘のとおり、変化量が大きいだけで目的関数と相関がないかはこれからだと判断できません。いろいろ考えたのですが、目的関数と無関係かを証明するのは難しいと思います。FB が大きく初期の値から変化したことはそこまで重要ではないのでこの図とそれに対応する部分は削除します。

Commented [広兼浩二朗21R17]: 了解した。その代わり思ったんやけど、この Figure5B の図は"重みの初期値が十分無視できる"っていう前提条件を示すために実は LA と Dual hebb のところで必要な図なのでは？

本文でも初期値が無視できる限りにおいて転置にな… [1]

にもかかわらず、固定 FB 重み LA モデルより緩やかではあったが、FF 重みと FB 重みのコサイン類似度の上昇と収束が認められた(~~Figure 5~~Fig. 4C)。この結果は、εとxの間に他の神経核が挿入され、複数の異なる予測符号化が混在している条件下でも、Loop Alignment が生じたことを示す。

次に、固定ランダム FB 重みを用いた LA モデルと比較して、同様に学習が収束するかを検証する。固定のランダム重みではなく可変のランダム重みを FB に適用する条件においても、ネットワークのエネルギーが学習の進行とともに一貫して低減することが確認された（~~Figure 5~~-Fig. 4D)。エネルギーはコサイン類似度と同様に、固定の FB 重みを用いる LA モデルより回路の一部が共有しているモデルの方が、緩やかな収束を示した。

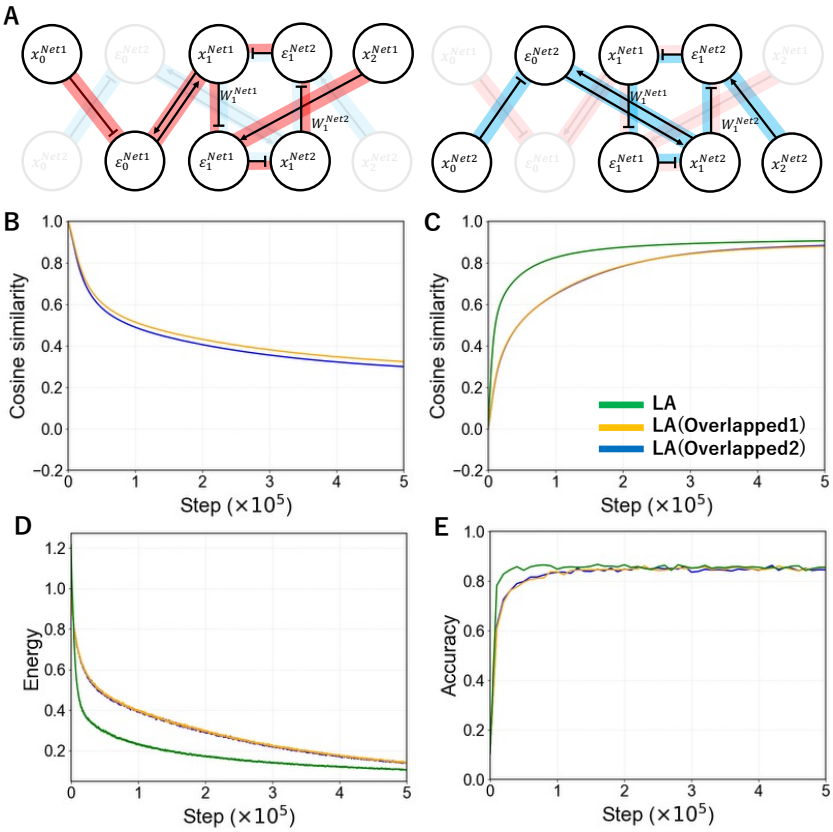

Figure 5：**2 つの系が回路を共有する LA モデルの解析**

2 つの LA モデル（Net 1 および Net 2）が回路の一部を共有した場合のアーキテクチャと学習挙動を示す。図 C–F において、緑線は固定ランダム行列を用いる通常の LA モデル、赤線は Net 1、黒線は Net 2 を表す。実線は 1 session あたり 3×10^6 iteration とした 10 session の平均値を示す。

Commented [広兼浩二朗22]: この図も点線と実線は同じように使い分けるべき。

A) **2 つの LA モデルが回路の一部を共有する構成：**LA モデルの中間層に相当する FB 経路が、別の LA モデルの FF 経路として機能することで、2 つの LA モデルが回路の一部を共有する構成を示す。
B) **FB 重みの動的変化量：**縦軸は、重みを共有する二つの L A モデルにおける FB 重み(黄色: Net 1, 青: Net 2)の初期値と、学習中の各 iteration における同じ重みベクトルとのコサイン類似度を示す。横軸は iteration 数を表す。
C) **コサイン類似度の推移：**縦軸は、回路を共有しない Single LA モデル(緑)、回路の一部を他の LA モデルと共有する LA モデルにおける FF 重みと FB 重みのベクトル間のコサイン類似度、横軸は iteration 数を示す。
D) **エネルギーの推移：**縦軸は、回路の一部を他の LA モデルと共有する LA モデルのエネルギー、横軸は iteration 数を示す。
E) **MNIST 分類タスクにおける精度推移：**縦軸は、LA 回路共有モデルの MNIST 分類精度、横軸は iteration 数を示す。

固定ランダム FB 重みを用いた LA モデルと比較し、同様に MNIST 画像分類タスクを遂行可能か検証した。実験結果により、動的なランダム FB 重みを用いる LA 回路共有モデル、および固定モデルのいずれにおいても、最終的な分類精度は約 85%に到達し安定した分類を実現できることを示している(~~Figure 5~~Fig. 4E)。これらの結果から、FB 重みは FF 重みの転置や、静的なランダム行列である必要がなく、実際の生体脳のように複数の機能モジュール間で回路が柔軟に共有・再利用される複雑な条件下であっても、LA のメカニズムが成立することが実証された。すなわち、LA は他タスクからの干渉を伴う動的な重み共有環境においても学習が可能な、ロバストな計算原理である。~~FB 重みに関しては、FF 重みの転置や、固定されたランダム行列といった制約が必須ではない可能性が示唆された。~~

ノイズ耐性

前節では、回路の共有という構造的な干渉に対する LA の頑健性を確認した~~三つの予測符号化回路が神経回路の一部を共有する条件下においても、LA が有効に機能することを示した~~。しかし、実際の神経回路では、シナプス結合そのものが常に揺らぎ続けるというノイズ問題が存在する~~さらに神経核間投射において大小さまざまな構造変化が生じることが報告されている~~。そこで本節では~~に示した LA モデルを用い~~、学習の各ステップにおいて FB 重みに一様分布から生成した動的ノイズを継続的に加算し~~目的関数と無相関な時間的構造変化をどの程度の強度まで~~、L A モデル~~ネットワーク~~がどこまで安定してエネルギー最小化と~~を減少させ、~~MNIST 分類~~タスク~~を遂行できるかを検証したすることを目的とする~~。~~具体的には、FB 重みに対して学習の各ステップで動的変化(ノイズ)を加え、その~~加算するノイズ量は、FB 重みの Xavier スケーリング値に対して±1%から~~、±2%、±3%、±5%、±10%、±20%、~~±30%までの~~の~~範囲~~から一様分布に従って~~生成し、~~た。~~重みが時間とともに動的に変動し続ける過酷な条件下でのロバストネスを評価した~~この操作により、FB 重みは学習中に動的に変化するよう設計した~~。

~~本モデルにおいても、これまでの検証と同様に MNIST 分類タスクを用いて学習を行なった。~~まず初めに、FB 重みの目的関数と無相関な時間的構造変化の影響の大きさを評価するため、学習初期からの変化を、コサイン類似度を用いて定量化した。300 万ステップに到達した時点で、全てのダイナミクス強度のパターンで初期の重みとの相関が失われる(コサイン類似度=0)ことを確認した(~~Figure 6~~Fig. 5A)。

次に、FF・FB 重み間のコサイン類似度の変化を、ノイズ~~重み変化量~~の強度ごとにどのように変化するか確認した。FB 重みの変化量が 1～10%の範囲では、両重みベクトル間の角度が学習初期に急速に増大した後、徐々に減少し、最終的にコサイン類似度が 0.2～0.4 付近で収束した一方で、FB 重みの変化量が 20～30%と大きい場合には、学習が進行してもコサイン類似度の上昇がほとんど見られず、最終的に 0 付近で収束した(~~Figure 6~~Fig. 5B)。過度に大きな FB 重みのノイズ~~変動~~が、FF および FB 経路間の整合性を阻害し、Loop Alignment の形成を妨げることを示している。

また、エネルギーは FB 重みの時間的構造変化の強度に関わらず、初期のエネルギーより低い値に収束することを示した(~~Figure 6~~Fig. 5C)。

モデルの分類精度は、FB 重みの時間的構造変化の強度が 1%、2%、3%、および 5%の場合、ランダム固定行列の場合と同等の成績を示す一方で、強度 10%の場合、ランダム固定行列のモデルと比較して分類精度はわずかに低下する（~~Figure 6~~Fig. 5D)。さらに、この強度が 20%、 30%に拡大すると、分類精度の低下はより顕著になった（~~Figure 6~~Fig. 5D)。

ここで、コサイン類似度が 0 以下になった学習ステップの数の割合を計測した(**表 1** ~~**表 1**~~)。FB 重みの時間的構造変化の強度が 1%～5%の場合、コサイン類似度が 0 以下になるステップは観測されなかった。一方、この強度が 10%を超える条件では、コサイン類似度が 0 以

Commented [広兼浩二朗23]: そもそもなんやけど、ノイズ実験を回路共有モデルでやれよと言われそう。

Commented [広兼浩二朗24]: もう一つ、BP＋FA にノイズを入れたら崩壊するのかを確認する必要があるかも。BP でもノイズ耐性があるならこの実験の意味はあんまりない気がしてきた。
逆に BP で崩壊するなら、メッセージはかなり明確

Commented [広兼浩二朗25]: これは何が言いたい？？
むしろ回路共有が構造的な干渉で、今回のノイズはシナプストランスミッション自体がノイズを含んでいるっていう生物学的な問題をシミュレーションしたのでは？
もし本当にシナプスがそもそも消えたり、結合が変わったりするのをシミュレーションしたいのなら、いきなり重みを消すとかしないとダメな気が。

Commented [広兼浩二朗26]: 再び、この初期値から離れていく現象は他のモデルでは起こらない現象なの？0 に行くから何？？

Commented [上27R26]: 動的変化が十分に大きいことを示しています。学習がうまくいったのは、FB のダイナミクスが小さいからなんじゃないかと言われないためです。

Commented [広兼浩二朗28]: 横軸が長すぎて、初期値エネルギーより現象してるのがいまいち伝わってこない。

Commented [上29R28]: 学習は 300 万まであるのに。エネルギーは 10 万までしか示さないというのは OK ですか？

Commented [広兼浩二朗30R28]: まあこのままでいいか、、

下になるステップが観測され、強度の増大に応じてその頻度は増加した。~~Figure 6~~-Fig. 5Dからも、変化量の強度が 10%を境に MNIST 分類精度が低下することが確認される。これらの結果は、MNIST 画像分類タスクにおける安定した学習のためには、FB 重みのコサイン類似度が少なくとも 0 以上で維持されることが重要であることを示唆している。

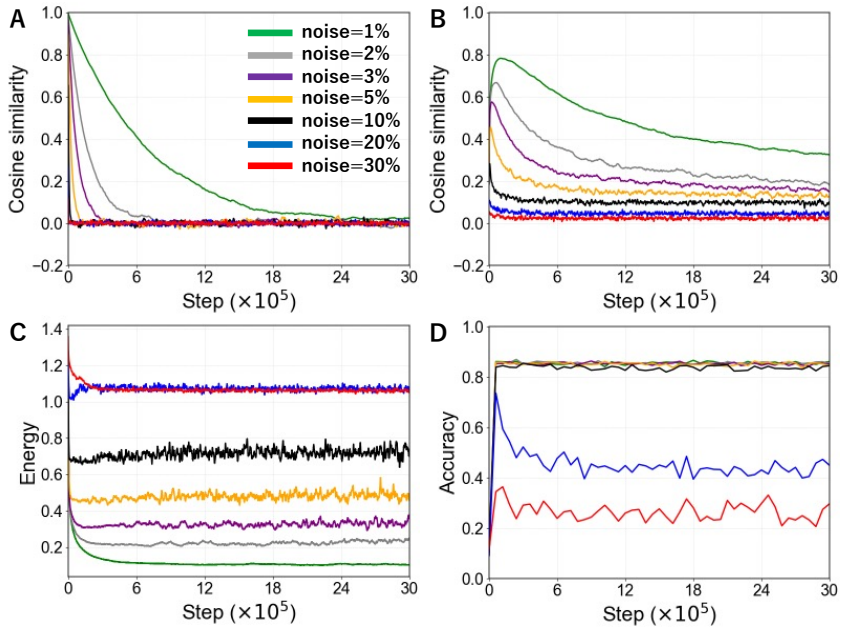

Figure 6:**FB 重みを動的なランダム重みに拡張**

LA モデルの重みが動的変化に対してどの程度耐性を有するかを検証した結果を示す。FB 重みには固定ランダム行列を用い、FF 重みに対して毎 Iteration 一定強度のノイズを付加した。ノイズ強度は Xavier スケーリングに対する割合として、1%（緑）、2%（灰）、3%（紫）、5%（橙）、10%（黒）、20%（青）、30%（赤）を用いた。各条件において、3×10^6 Iteration を 1session とした 10session の平均値を実線で示す。

A) **FB 重みの動的変化量**：縦軸は、毎 Iteration ノイズが付加される FB 重みの初期値と、各 Iteration における FB 重みベクトルとのコサイン類似度を示す。横軸は Iteration 数を表す。

B) **コサイン類似度の推移**：縦軸は、FB 重みに動的変化が導入された際の LA モデルにおける FF 重みと FB 重みのベクトル間のコサイン類似度、横軸は Iteration 数を示す。

C) **エネルギーの推移**：縦軸は、FB 重みに動的変化が導入された LA モデルのエネルギー、横軸は Iteration 数を示す。

D) **MNIST 分類タスクにおける精度推移**：縦軸は、FB 重みに動的変化が導入された LA モデルの MNIST 分類精度、横軸は学習 Iteration 数を示す。

教師あり学習において FF・FB 重みが完全に一致している必要はないものの、誤差伝播を成立させるための最低限のアライメント閾値が存在することを示した~~教師あり学習を行う場合では、FF・FB 重み間のコサイン類似度が 0 を下回らない条件においてはタスクの遂~~

Commented [広兼浩二朗31]: コサイン類似度が 0 以下になるとなぜ崩壊するの？もし 0 以下の類似度と学習の崩壊の相関関係を主張したいなら、同じノイズレベルでも、trial によって 0 以下の類似度が出現した trial と出現しない trial があったはずで、その二つの精度を比較して統計とれば示せるかも。
あるいは cosine 類似度が 0 以下になると崩壊する数学的根拠を示すか。どっちかが必要。

Commented [上32R31]: 承知しました、実験してみます。

Commented [上33R31]: コサイン類似度が数回だけ 0 を下回るだけでは正答率に差があまりみられませんでした。議論するための結果を出すのは難しいかもしれません。

Commented [広兼浩二朗34R31]: じゃあこのコサイン類似度が 0 以下云々の主張は消す感じかな。もしコサイン類似度 0 以下と崩壊に関連がないなら表もいらないかも。

~~行ができることを示した~~。特筆すべきは、Xavier スケールの 5% 程度の変動においては、FF 重みと FB 重みのコサイン類似度が約 0.1~0.3 と低い場合でも学習が成立し、完璧なアラインメントは必ずしも学習に必要でない~~する~~ことを確認した。これらの結果は、~~FF 重みと FB 重みが構造的に一致している必要がなく、~~FB 重みが徐々に変化する動的な条件下でも PC が成立することが示した~~された~~。

表 1：コサイン類似度が負になる回数

	trial1	trial2	trial3	trial4	trial5	trial6	trial7	trial8	trial9	trial10
1%	0	0	0	0	0	0	0	0	0	0
⋮										
5%	0	0	0	0	0	0	0	0	0	0
10%	6.7E-07	0	0	2.3E-06	3.7E-06	9.0E-06	8.7E-06	8.0E-06	3.0E-06	0
20%	3.5E-03	3.3E-03	3.4E-03	3.2E-03	3.2E-03	3.5E-03	3.3E-03	3.1E-03	3.2E-03	3.1E-03
30%	1.1E-02	1.2E-02	1.1E-02	1.1E-02	1.1E-02	1.1E-02	1.1E-02	1.1E-02	1.2E-02	1.1E-02

Commented [広兼浩二朗35]: これは本当？？例えば noise=20%を見ると FigB では、cos sim が安定して 0 以上に見えるけど学習は失敗してる。何か違うことを言わないとダメな気がする。

Commented [広兼浩二朗36]: 再び、構造的に一致しているとはどういう意味？ここで検証したこととかなり違うニュアンスな気がする。

議論

1. まとめ Loop Alignment は、重み転置問題を解決したＰＣである

本研究は、脳の計算原理として有望視されながらも、生物学的妥当性に欠ける予測符号化モデルに対し、特に「重み転置問題」を克服する新しいアーキテクチャを提示することを目的とした。従来の予測符号化モデルでは、フィードフォワード（FF）とフィードバック（FB）経路の重みが転置関係にあることを前提としており、実際の神経回路において二つの大きな問題を抱えている。第一に、物理的に分離した FF・FB 結合が、学習過程において同期的に更新される必要がある点。第二に、解剖学的には、全ての細胞ペア間で単一シナプスの双方向性結合が存在するわけではない点である。まず、FF・FB 両経路を Hebb 則により独立に更新する Dual Hebb モデルを実装し、学習を通じて双方向の結合が自然に同期することを示し、第一の課題を解決した。さらに、ランダム固定行列や動的ノイズを FB 経路に導入することで、FB 重みと FF 重みが独立した更新系を持つ LA モデルを提案した。そこで、たとえ FB 重みが無相関なランダム構造や、他タスクと共有され変動する回路であっても FF 重みが FB 重みに自発的に整列していく現象を確認した。この現象は、重み転置問題の第二に問題を解決し、我々はこれを Loop Alignment（LA）と命名した。以上の結果は、提案された LA 予測符号化モデルが高い拡張性と頑健性を有することを示すものであり、脳内に存在する多様な神経回路構造に対しての、予測符号化理論の適用可能性を飛躍的に拡張するものである。

2. LA は実際の脳のように、柔軟かつ頑健なネットワークである

本研究の最も重要な知見の一つは、複数のタスクが神経回路の一部を共有し、FB 信号が動的に変動する環境下においても、LA がロバストに機能した点である。実際の脳において、神経核は単一の機能に専有されることは稀であり、常に他領域からの干渉（Interference）や自発活動を含む「ノイズの多い」FB 信号を受け取っている。我々のモデルが示した回路共有タスクでの成功は、LA が単なる誤差伝播以上の機能を持っていることを示唆する。LA における重み更新の式（１３）において、第一項は通常のヘブ則の学習項、第三項は FB 重みの定数倍というドリフト項であったが、第二項（$\varepsilon_i(\mathrm{t})\varepsilon_{i-1}(\mathrm{t})^{\mathrm{T}}$）は、前後のレイヤーにおけるエラーニューロンのクロス相関を重みから減算することで、エラーニューロンの活動の直交化を実現し、干渉を抑制する調整項として機能したと考えられる。この項が重み共有タスクにおいて寄与したと我々は考えている。例えば、下位レイヤー(i-1)において Net1 に対するエラー活動$\varepsilon_{i-1,(Net1)}$と Net2 に対するエラー活動$\varepsilon_{i-1,(Net2)}$があったとした時、それら二つのネットワークから同時に入力をおける上位レイヤー(i)におけるエラー活動ε_iは二つのエラーが混ざった活動を示すと考えられる。ここで、エラーニューロン間のクロス相関を減らす項が存在することによって、Net１、または Net２のどちらにも引っ張られることなく学習が行える。このように、FF 重みは他タスク由来の不要な相関を排除しつつ、

必要な情報のみを抽出・定着させることができる。これは、脳が限られた神経リソースを複数の認知機能で柔軟に使い回すための、計算論的基盤である可能性がある。

また、本研究の LA モデルが強烈なノイズ耐性を示した本質的な理由は、重み更新に先立って行われる反復的な推論ループにある。LA では、各入力に対してネットワークが数十回のループ処理を行うことで、その瞬間のノイズを含んだ FB 重み(B)の構造に対して表現ニューロンとエラーニューロンの活動がリアルタイムに適応し、誤差信号を安定化させる。これは BP ベースの FA では不可能な、L A ならではのロバストな計算特性である。

Commented [広兼浩二朗37]: もし BP＋FA の実験ができないなら、Discussion に適当に推測を書いておくだけでもいいかも。もちろんデータがあるに越したことはない。

3. LA モデルの立ち位置

本研究で提案した Loop Alignment（LA）は、生物学的妥当性を志向した既存の学習モデル群の中で、独自の位置づけを有している。従来、重み転置問題に対する代表的な解決策としては、Feedback Alignment（FA）に代表されるように、固定でランダムな FB 重みを用いながらも、FF 重みが誤差信号の近似方向へと整列していく現象が報告されてきた。一方で、これらのモデルは主として誤差伝播の近似可能性に焦点を当てており、FB 経路自体が学習過程においてどのような役割を果たし得るかについては、限定的な議論にとどまっていた。

また、Equilibrium Propagation(参考文献) や局所的な Hebb 則に基づく学習モデルは、生物学的実装可能性の観点から高い評価を受けているものの、ネットワーク全体が平衡状態へと収束することや、自由相と摂動相という二段階のダイナミクスを明確に切り替える必要がある点については、実際の神経回路における実装可能性という観点から議論の余地がある。さらに、これらのモデルは明示的な予測誤差の表現や、双方向結合の整合性という点では、必ずしも予測符号化の枠組みを直接的に拡張するものではない。

Commented [上38]: Equiilibrium Propagation モデルはざっとしか読んでないのですが、調べてみた感じ、学習則は生物学的にいいのですが、ネットワークとしての記述が難しいみたいです。

加えて、LA は、FB 重みが固定・ランダム、あるいは他タスクと共有され時間的に変動する状況下においても、FF 重みが FB 経路を含む再帰的ループ構造全体へと自発的に整列していくという点で特徴がある。すなわち LA は、「重みの一致」そのものを仮定するのではなく、回路内に存在する再帰的ループのダイナミクスを通じて、予測誤差の伝播に十分な構造が形成されることを示している。この観点から、LA は FA や従来の予測符号化モデルを包含しつつ、より一般的かつ柔軟な回路条件下においても成立する学習原理を与えるものと位置づけられる。したがって本研究の結果は、特定の解剖学的な構造や、厳密な重み対称性に依存することなく予測符号化が実装可能であることを示唆しており、生物学的神経回路における計算原理の理解を一段深めるものと考えられる。

4. モデルをミニマルにすることによって、LA の根本的な頑健性を示した。

本研究において、転置モデルの分類精度は先行研究と比較して低い値にとどまった[6]。しかし、この差異はモデルの能力の欠如を示すものではなく、我々が現代的な深層学習で

使われる技術(Optimizer, ReLU などの非線形活性化関数, Normalization など)を意図的に排除し、純粋な局所 Hebb 則のみで構成された Minimal なモデルを採用した結果である。これらの技術の中には、発火閾値や Homeostatic plasticity、側抑制といった実際の神経メカニズムに近似できるものも存在するが、それらを導入すると、精度向上をもたらした要因がそれら非線形な操作にあるのか、LA 現象にあるのかを分離することが困難になる。~~そのような工学的な最適化手法は、学習の安定性と収束速度を劇的に向上させるが、その生物学的対応は不明である。~~よって、本研究では、LA が補助的なテクニックに依存しない基本原理であることを証明するため、あえてこのような厳しい条件で検証を行った。このような生物学的に妥当な設定のもとで行われた実験において、ロバストな学習、およびアラインメントが起こった事実は、提案手法の生物学的妥当性を支持する。精度の向上については、今後、Dale の法則を考慮した重みの実装や、スパイキングニューラルネットワークへの拡張など、より詳細な解剖学的特徴を導入することで、生物学的リアリティを損なうことなく達成され得ると期待しており、将来の実験が待たれる。

5. ランダム FB 重みは worst case scenario であって、脳がランダムという主張ではない

我々は FB 結合としてランダム行列を用いたが、これは実際の脳内結合がランダムであることを主張するものではない。むしろ、脳内において FB 結合が完全に無相関である可能性は低いと考えられる。実際、解剖学的および生理学的には、皮質間結合は層構造や細胞型に応じた非対称性を有し（文献)、機能的にはトップダウン注意や文脈を伝達する役割を担っていると考えられる。つまり、本研究が示した結果は、FB 結合がどのような情報処理的役割を担っていたとしても、最悪のケースであるランダム結合においても、さらにはそれにノイズが加わる条件下ですら学習が成立したということである。これは、L A の高い可塑性を証明した結果であり、FF・FB 結合の対称性や等強度性という強い仮定を課さずとも予測符号化に基づく学習が成立し得ることを示した点で、生物学的により妥当な予測符号化モデルの構築に向けた重要な理論的基盤を提供するものである。

6. モノシナプティック双方向性結合問題は全結合を前提とする

本研究のモデルでは、計算の簡便性と情報の広域的な伝播を確保する目的から、ランダム行列を用いた双方向の全結合構造を採用している。しかし、この構成に内在する「任意の細胞から元の細胞へと戻る再帰的ループが必ず存在する」という仮定については、生物学的妥当性の観点から慎重な検討が必要である。実際の皮質回路は極めてスパースであり、シナプス結合には非対称性があるため、すべての神経細胞が全結合のネットワークを形成しているわけではない。このような全結合の仮定は、生体が有する機能的階層構造や情報の分離を過度に単純化している可能性がある。

一方で、本モデルによるアプローチは、複雑な生体神経回路における情報処理の基本原理を抽出するための「第一近似」として極めて有用であると考えられる。今後は、興奮

Commented [広兼浩二朗39]: ディスカッションで入れようと言ったのは自分なんやけど、いざ読んでみるとなんか弱いな。

1-2 文にまとめてパラグラフ 5 にくっつけるか

性・抑制性バランスといった要素を取り入れた、より解剖学的制約の強いアーキテクチャにおいても、本研究で得られた知見がどの程度頑健に維持されるかを検証することが、計算論的神経科学の発展において重要なステップとなると考えられる。さらに今後の発展として、結合確率を制限したスパースな接続構造を導入し、結合密度が学習ダイナミクスやネットワークの安定性に与える影響を体系的に検討することも重要な課題である。

7. まとめ、BP に甘んじるのではなく真に生物学的に妥当なネットワークを作ろう

近年、人工ニューラルネットワークの性能向上に伴い、脳の情報処理機構に着想を得た数理モデルが数多く提案されている。しかし、その多くは依然として Backpropagation（BP）を基盤としており、本質的には生物学的妥当性を欠く工学的最適化手法の延長にとどまっている。BP は、順伝播と誤差逆伝播という時間的に分離されたフェーズを前提とし、全層にわたる大域的な誤差信号の伝播や、重みの転置という物理的に存在しない経路を必要とし、脳の情報処理理論としては重大な問題を抱えている。つまり、Feedback Alignment など BP の生物学的妥当性を議論する手法は工学的には有用であるものの、脳内情報処理の実態を説明するモデルとしては限界がある。

これらの問題に対し、L A モデルでは、誤差信号は大域的に伝播されるのではなく、各層における局所的な Hebb 則によって計算され、隣接する層間でのみやり取りされる。さらに重要なことに、LA は学習を静的な重みの更新としてではなく、神経活動の同時並行的な双方向相互作用を通じた、重みの動的な整列プロセスとして再定義した。この点で、LA モデルは BP が抱える大域的誤差伝播依存性や生物学的非現実性を回避する枠組みである。したがって、予測符号化モデルにさらなる生物学的制約や構造的非対称性を導入し、その機能的意義を検証する本研究のアプローチは、脳の情報処理原理の理解において重要である。

Methods

Baseline モデル

本研究では、Whittington & Bogacz による転置モデルに基づく予測符号化ネットワークを用いて数値シミュレーションを行った。各階層 i において、表現ニューロンの活動量を x_i、対応するエラーニューロンの活動量をε_i、表現ニューロンとエラーニューロン間のフィードフォワード結合重みを W_i と定義する~~（(図~~Fig. 1-A)。同一階層内の表現ニューロンからエラーニューロンへの接続方向をフィードフォワード（FF)、その逆方向をフィードバック（FB）と呼ぶ。

上位階層の表現ニューロンは、FB 結合を介して下位階層の活動を予測し、その予測と実際の下位層活動との差分が予測誤差としてエラーニューロンにより符号化される。本研究では、各階層における予測誤差 ε_i を次式で定義する。

$$\varepsilon_i = x_{i+1} - W_i x_i \tag{17}$$

ここで、予測誤差の分散は 1 と仮定したが、数式上は明示的には記載していない。

予測符号化の枠組みにおいては、システム全体の動作はエネルギー関数の最小化として定式化される。エネルギー関数は各階層における予測誤差の二乗和から構成され、階層的な予測と誤差修正を繰り返す脳内情報処理過程を数学的に表現している。エネルギー関数 E を以下のように定義した。

$$E = \sum_{i=1}^{N} (\varepsilon_i)^2 \tag{18}$$

このエネルギー関数を最小化するため、表現ニューロンの活動量 x_i および結合重み W_i を、それぞれ勾配降下法に基づいて更新した。エネルギー関数に対する勾配は次式で与えられる。

$$\frac{\delta E}{\delta x_i} = -\varepsilon_{i-1} + \varepsilon_i W_i^T \tag{19}$$

$$\frac{\delta \mathrm{E}}{\delta W_i} = x_i^T \varepsilon_i \tag{20}$$

Commented [広兼浩二朗40]: この二つの式はどういう展開？？ちょっと計算が合わない。

本研究におけるシミュレーションでは、推論過程と学習過程を明確に分離した。各入力サンプルに対して、まず結合重み W を固定した状態で表現ニューロンの活動量 x のみを更

新し、エネルギー関数が局所的に最小化されるまで推論を行った。具体的には、表現ニューロンの更新を 1 iteration あたり 50 loop、この固定 loop 数をもって推論の収束条件とした。表現ニューロンの更新は勾配量に更新率を乗じた逐次更新として実装された。一方、エラーニューロンの活動量 ε は各更新ループにおいて、隣接する表現ニューロンの活動から直接計算され、活動量が完全に置き換わる設定とした。

学習過程終了後、得られた表現ニューロンおよびエラーニューロンの活動に基づいて、結合重み W を勾配降下法により更新した。表現ニューロンおよび結合重みの更新にはそれぞれ独立した更新率を用いた。

ネットワーク構造は 3 層構成とし、表現ニューロン数は入力層から順に 784–100–10、対応するエラーニューロン数は 100–10 とした。結合重みの初期値は、Xavier スケーリングに基づき、平均 0 の正規分布からランダムにサンプリングした。それぞれのネットワークは同一分布からサンプリングされたが、異なる乱数系列により初期化された。シミュレーションで用いたすべてのパラメータおよび初期値は表◯に示す。

教師データの提示方法として、MNIST 画像を最下位層の表現ニューロンに入力し、対応するクラスラベルを one-hot ベクトルとして最上位層の表現ニューロンに与えた。学習中は、入力画像およびラベルの両方をクランプした状態で推論および学習を行った。学習は 20 サンプルごとのミニバッチ学習として実施し、各サンプルに対して推論および重み更新を逐次的に行った。

Commented [広兼浩二朗41]: つまり 50 loop が 1 iteration ってこと？
ここのステップは何を意味する？
Loop という言葉を Result で使うんやったら、Loop を説明しているところは、Loop という言葉を使って説明したほうがいいと思う。
あちこちあるから、全体を見直して Methods を直して欲しい。

ループ＜イテレーション＜セッション という関係性も崩さないように。
ステップはもっと概念的な手順を説明するときのみ使う。これを徹底しよう。

Commented [広兼浩二朗42]: 作成中？

Algorithm 1：Baseline model 学習機序

```
x_0 ← x_input                                  // 入力x_input が最低次(0)の表現ニューロンに与えられる
x_N ← x_output                                 // 入力x_output が最高次(N)の表現ニューロンに与えられる
for _loop ← 1 to num_loop do                   // ある画像に対して表現ニューロンの更新をnum_loop回繰り返し行う
    for i ← 0 to N − 1 do                      //N・N-1レベルの表現ニューロン間のエラーニューロンまで計算する
        ε_i ← x_{i+1} − W_i x_i                //エラー神経細胞の活動量を計算する
    end for
    for i ← 1 to N − 1 do                      // 最低次と最高次の表現ニューロン以外更新する
        x_i ← x_i − η_x(ε_{i−1} − ε_i W_i^T)   //η_x は学習率, 表現ニューロンを更新する
    end for
end for
for i ← 0 to N − 1 do                          //最高次以外の表現・エラーニューロン間重みを計算する
    W_i ← W_i − η_W x_i^T ε_i                  //η_W は学習率, 重みW_i を更新
end for
```

Dual Hebb モデル

Dual Hebb モデルでは、予測符号化におけるフィードバック結合の生物学的妥当性を高めることを目的として、FF 結合と FB 結合を独立した学習系として扱う。baseline model では、各階層において FB 重み (W_i^{FB})は FF 重み(W_i^{FF})の転置として明示的に定義され、学習過程においても W_i^{FF} の情報を直接コピーすることで W_i^{FB} が与えられていた。一方、Dual Hebb モデルでは、W_i^{FF} と W_i^{FB} を独立した結合として定義し、それぞれが異なる学習則に従って更新される点が最大の特徴である。

具体的には、FF 重み W_i^{FF} は baseline モデルと同様に、エネルギー関数に基づく勾配降下法によって更新される。一方、FB 重み W_i^{FB} はW_i^{FF}とは独立に保持され、表現ニューロンとエラーニューロンの同時活動に基づく Hebb 則に従って更新される。本研究では、FF・FB 重みの更新則を式◯で定義した。

ここで、η はフィードバック重みに対する学習率を表す。なお、この更新則にはフィードフォワード重みの情報は一切含まれておらず、局所的な活動情報のみに基づく更新となっている。

学習過程における表現ニューロンおよびエラーニューロンの更新手順、ならびにエネルギー関数の定義、表現ニューロンの収束判定条件、学習のオンライン/バッチ構成、MNIST データセットの前処理方法、評価指標（エネルギーおよび分類精度）については、条件を統一するために baseline モデルと同一の設定を用いた。実験に用いたパラメータは表◯に示す。各入力サンプルに対して表現ニューロンの活動量を 50 loop した後に重み更新を行い、20 サンプルごとのミニバッチ学習を採用した。

Commented [広兼浩二朗43]: ループ？

Commented [広兼浩二朗44]: Dual Hebb も Pseudo Code お願いしたい。基本的には WFF と WFB の同時更新っていうだけやけど、どこが baseline と違うかを highlight してわかりやすく。

LA モデル

Loop Alignment（LA）モデルでは、予測符号化における FB 結合の生物学的妥当性をさらに高めることを目的として、FB 重みを学習対象から除外し、固定されたランダム結合として与える。Baseline model は、各階層において FB 重み(W_i^{FB})が FF 重み(W_i^{FF}) の転置として明示的に定義され、学習過程においてもW_i^{FF} の情報を直接コピーすることで W_i^{FB} が与えられていた点にある。

これに対し、LA モデルでは、FB 重みW_i^{FB}に固定のランダム行列 B_i を用いる。これらのランダム行列は学習中に更新されることはなく、FF 重みの初期値と同様に、Xavier スケーリングに基づく正規分布からランダムサンプリングすることで初期化した。したがって、LA モデルでは、FF 結合と FB 結合の間に明示的な重み共有や転置制約は一切課されていない。

学習過程においては、表現ニューロンの活動量を勾配量に更新率を乗じた逐次更新によって反復的に更新し、各入力サンプルにつき表現ニューロンの更新を 50 loop 行った後に、FF 重みのみを更新した。FF 重みの更新則、エネルギー関数の定義、学習率、ミニバッチ構成、MNIST データセットの前処理方法、ならびに評価指標（サンプルごとのエネルギー値および分類精度）については、条件を統一するために baseline モデルおよび Dual Hebb モデルと同一の設定を用いた。

ただし、動作機序の解析を目的とした実験においては、各入力サンプルにつき表現ニューロン~~の更新回数~~を 1、3、5、10 loop 更新~~回と~~した条件で同様の評価を行った。

入力データ

本研究では、手書き数字画像データセットとして 標準的な MNIST データセットを用いた。各画像は 28×28 ピクセルのグレースケール画像であり、画素値を 0–1 の範囲に正規化した上で入力として用いた。各入力画像は 784 次元のベクトルに展開され、最低次の表現ニューロン層に対応する 784 個のニューロンへと直接入力された。

ネットワークは 3 層構造とし、最低次の表現ニューロン層から順に 784–100–10 個の表現ニューロンを配置した。最低次層では、入力画像を対応する表現ニューロンの活動量としてクランプし、その状態を維持したまま上位層の推論および学習を行った。最高次層においては、分類タスクに対応する教師信号として、正解ラベルを表す 10 次元の One-hot ベクトルを表現ニューロンの活動量として与え、同様にクランプした状態で学習を行った。

解析メトリクス

コサイン類似度

FF 重みと FB 重みの構造的類似性を定量的に評価するため、両者の重みベクトル間のコサイン類似度を計算した。表現ニューロンの数を n、エラーニューロンの数を m とする。このとき、表現ニューロンからエラーニューロンへのフィードフォワード（FF）重み行列の次元は[n, m]であり、これを要素数 n×m の一次元ベクトルWに変換した。同様に、エラーニューロンから表現ニューロンへのフィードバック（FB）重み行列の次元は[m, n]であり、これを要素数 m×n の一次元ベクトルBに変換した。なお、FB 重み行列については、FF 重み行列との対応を保つため、転置を施した上で一次元ベクトルへ変換した。これにより、同一の表現ニューロン–エラーニューロン対に対応する重みが、両ベクトルにおいて同一のインデックスに配置される。これら二つのベクトルWおよびBに対して、以下に示す式を用いてコサイン類似度を算出した。

$$\cos(W, B) = \frac{\langle W, B \rangle}{\|W\| \|B\|} \tag{21}$$

コサイン類似度の計算は、教師あり学習において1sessionが完了するごとに、各学習ステップで実施した。

精度(accuracy)

分類性能の評価には、一般的な教師あり分類と同様に、推論後の最上位層の表現ニューロン活動のうち最大の活動値を示すニューロンに対応するクラスを予測クラスとして採用し、正解ラベルとの一致率（accuracy）を指標として用いた。

Commented [広兼浩二朗45]: マックス活動量のラベルを出力としたのか？それともシグモイドとか softmax で出力したのか？

エネルギー

全てのモデルにおいて、エネルギーは式(9)に基づき、サンプルごとに算出し、その時間変化を解析した。

重み共有タスク

本研究では、LA モデルにおいてフィードバック（FB）重みが固定されたランダム行列であるという仮定を緩和し、FB 重みが学習過程を通じて動的に変動する条件下においても、LA モデルが適切に機能するかを検証することを目的とした。そのために、2 つの 3 層構造からなる予測符号化回路が、第 2 層における表現ニューロンおよびエラーニューロンのフィードフォワード（FF）および FB 経路を共有するモデルを構築した。

使用する 2 つの LA モデル回路はいずれも 3 層構造とし、それぞれを Net1 および Net2 と定義する。両回路における対応する状態変数およびパラメータは、上付き文字によって区別する（Net1 の第 2 層表現ニューロンをx_1^{net1}、Net2 をx_1^{net2}と表記する）。

学習には MNIST データセットを用い、同一のパラメータ設定の下で Net1 および Net2 を同時に学習させた。ただし、同一学習ステップにおいて、Net1 および Net2 には異なる入力画像を一枚ずつ与え、ミニバッチ入力は行わなかった。同一のデータプールから、各モデルに対して独立に入力画像をランダムサンプリングした。すなわち、学習ステップ t において、Net1 には入力画像 $s^{net1}(t)$、Net2 には $s^{net2}(t)$ を与え、両モデルは異なるランダムシードに基づいて入力画像をシャッフルした。

本モデルの特徴は、第 2 層においてx_1^{net1}、ε_1^{net1}、x_1^{net2}、ε_1^{net2}からなる神経核が相互にループ構造を形成し、FF 重みおよび FB 重みを両ネットワーク間で共有する点にある。共有される FB 重みを W_FB とすると、各ネットワークにおける第 2 層の予測誤差は次式で定義される。

$$\varepsilon_i^{net1} = x_{i+1}^{Net1} - x_i^{Net1} W_i^{Net1} \tag{22}$$

$$\varepsilon_i^{net2} = x_{i+1}^{Net2} - x_i^{Net2} W_i^{Net2} \tag{23}$$

$$x_i^{Net1} = -\varepsilon_{i-1}^{Net1} + \varepsilon_i^{Net1} B \mathrm{W}_i^{\mathrm{Net2}} B \tag{24}$$

$$x_i^{Net2} = -\varepsilon_{i-1}^{Net2} + \varepsilon_i^{Net2} B \mathrm{W}_i^{\mathrm{Net1}} B \tag{25}$$

$$W_i^{net1} = x_i^{Net1} \varepsilon_i^{Net1}$$

$$W_i^{net2} = x_i^{Net2} \varepsilon_i^{Net2}$$

Commented [広兼浩二朗46]: ΔW って言いたい？式番号足してね。

ここで x_2^{net1} および x_2^{net2} は、それぞれ Net1 および Net2 における上位層の表現ニューロンを表す。このように、本モデルでは各ネットワークの表現ニューロンが、他方のネットワークの上位表現を用いて予測される構造を採用している。

表現ニューロンの状態更新および誤差ニューロンの計算は、LA モデルと同一の推論ダイナミクスに従って行われる。一方で、FB 重み W_FB は両ネットワークに共通であり、その更新は Net1 および Net2 の双方における誤差信号に基づいて行われる。具体的には、各学習ステップにおいて、Net1 および Net2 から得られる勾配を加算する形で、次式により更新した。

ΔW_FB = η (ε _1^net1 (x_2^net2)^T + ε _1^net2 (x_2^net1)^T)

ここで η は学習率を表す。この更新則により、FB 重みは一方のネットワークの誤差だけでなく、他方のネットワークの状態にも依存して更新されるため、LA モデルにおいて通常は固定されている FB 重みが、学習過程を通じて動的に変動する条件が実現される。なお、本モデルでは FB 重みに対して明示的なノイズ付加や追加的な更新項は導入していない。

シミュレーションに用いた各種パラメータ設定、MNIST データの前処理方法、推論ステップ数、評価指標については、baseline モデルおよび通常の LA モデルと条件を統一した。学習手順の詳細を Algorithm◯に示す。Algorithm◯は Net1 に対応する処理を示したものであり、Net2 に対するアルゴリズムは、Algorithm◯における上付き文字 net1 を net2 に、net2 を net1 に置き換えることで定義される。Net1 および Net2 のいずれにおいても、Algorithm 5 に示す一連の処理を 1 学習ステップとして定義した。

表 2~~12~~ LA モデル Fig7(回路共有)パラメータ

Variable	Value	Description
$\boldsymbol{N}$	3	レイヤー数
$\boldsymbol{X}$	784-100-10	表現ニューロンの活動量. 初期値は0.
$\boldsymbol{\varepsilon}$	100-10	表現ニューロン間の誤差を計算するエラーニューロンの活動量. 初期値は0.
$\boldsymbol{num_Loop}$	10	表現ニューロンの更新回数
$\boldsymbol{W}$	Xaviar初期値	表現ニューロン・エラーニューロン間の結合重み,全結合層(FC)
$\boldsymbol{W_{rand}}$	Xaviar初期値	回路Aエラーニューロン・回路B表現ニューロン間の結合重み,全結合層(FC)
$\eta_{\boldsymbol{X}}$	0.25	表現ニューロンの更新率
$\eta_{\boldsymbol{W}}$	0.125	結合重みの更新率
$\boldsymbol{\sigma}$	1	事前分布の分布

Algorithm 2~~5~~：回路を共有する LA モデル学習機序

1.	$x_0^{PC1} \leftarrow x_{input}$	// 入力$\boldsymbol{x}_{\mathrm{input}}$が最低次(0)の表現ニューロンに与えられる
2.	$x_N^{PC1} \leftarrow x_{output}$	// 入力$\boldsymbol{x}_{\mathrm{output}}$が最高次(N)の表現ニューロンに与えられる
3.	**for** _loop ← 1 to num_loop **do**	// ある画像に対して表現ニューロンの更新をnum_loop回繰り返し行う
4.	**for** i ← 0 to $N-1$ **do**	//N・N-1レベルの表現ニューロン間のエラーニューロンまで計算する
5.	$\varepsilon_i^{PC1} \leftarrow x_{i+1}^{PC1} - W_{rand}^{PC1} 1 W_i^{PC1} W_{rand}^{PC2} x_i^{PC1}$	//エラー神経細胞の活動量を計算する
6.	**end for**	
7.	**for** i ← 1 to $N-1$ **do**	// 最低次と最高次の表現ニューロン以外更新する
8.	$x^{PC1}{}_i \leftarrow x_i^{PC1} - \eta_{\boldsymbol{x}}(\varepsilon_{i-1}^{PC1} - \varepsilon_i^{PC1} W_i^{PC2})$	//$\eta_{\boldsymbol{x}}$は学習率, 表現ニューロンを更新する. ランダム行列Bを用いる
9.	**end for**	
10.	**end for**	
11.	**for** i ← 0 to $N-1$ **do**	//最高次以外の表現・エラーニューロン間重みを計算する
12.	$W_i^{PC1} \leftarrow W_i^{PC1} - \eta_{\boldsymbol{W}}\left(x_i^{PC1}\right)^T \varepsilon_i$	//$\eta_{\boldsymbol{W}}$は学習率, 重み$\mathrm{W_i}$ を更新
13.	**end for**	

ノイズタスク

FB 結合が学習過程を通じて時間的に変動する状況下における予測符号化モデルの頑健性を評価するため、FB 重みに対して人工的にノイズを付加する設定を導入した。評価タスクとしては、他の実験と同様に MNIST 画像分類タスクを用いた。ネットワーク構造、推論過程、フィードフォワード重みの更新則、教師信号の与え方、学習率、ミニバッチ構成、データ前処理方法については、LA モデルの基本設定と同一とした。

本実験では、フィードバック重み行列 B を Xavier スケーリングに基づく正規分布からラ

ンダムに初期化する点は LA モデルと同一であるが、学習中に B を固定せず、各学習ステップにおいてノイズを付加する点が異なる。具体的には、各学習ステップ t において、フィードフォワード重みの更新を行う直前に、フィードバック重み行列 B(t) を以下の式に従って更新した。

$$B(t+1) = B(t) + noise(t) \tag{26}$$

ここで、ノイズ項 (nosie)は、各要素が独立に一様分布からサンプリングされた行列であり、その大きさは B の初期化に用いた Xavier スケーリング値を基準として設定した。

$$noise(t) \sim U(-\eta\sigma_{Xav}, \eta\sigma_{Xav}) \tag{27}$$

σ_{Xav} は Xavier スケーリングによって定まる標準偏差、η はノイズ強度を制御する係数である。本研究では、η を 1%、2%、3%、5%、10%、20%、30% の条件で設定し、それぞれについて独立に学習実験を行った。各ノイズ強度条件において、分類精度およびサンプルごとのエネルギー値を指標として学習の成否を評価した。シミュレーションに用いた各種パラメータ設定および初期値は表 ◯ および表 ◯ に示し、学習アルゴリズムおよび推論・更新手順の詳細は Algorithm ◯ に示す。

1.	$x_0 \leftarrow x_{input}$	// 入力$\boldsymbol{x}_{\mathrm{input}}$が最低次(0)の表現ニューロンに与えられる
2.	$x_N \leftarrow x_{output}$	// 入力$\boldsymbol{x}_{\mathrm{output}}$が最高次(N)の表現ニューロンに与えられる
3.	**for** _loop ← 1 to num_loop **do**	// ある画像に対して表現ニューロンの更新をnum_loop回繰り返し行う
4.	**for** i ← 0 to $N-1$ **do**	//N・N-1レベルの表現ニューロン間のエラーニューロンまで計算する
5.	$\varepsilon_i \leftarrow x_{i+1} - W_i x_i$	//エラー神経細胞の活動量を計算する
6.	**end for**	
7.	**for** i ← 1 to $N-1$ **do**	// 最低次と最高次の表現ニューロン以外更新する
8.	$x_i \leftarrow x_i - \eta_{\boldsymbol{x}}(\varepsilon_{i-1} - \varepsilon_i B_i)$	//$\eta_{\boldsymbol{x}}$は学習率, 表現ニューロンを更新する. ランダム行列Bを用いる
9.	**end for**	
10.	**end for**	
11.	**for** i ← 0 to $N-1$ **do**	//最高次以外の表現・エラーニューロン間重みを計算する
12.	$W_i \leftarrow W_i - \eta_{\boldsymbol{W}} x_i^T \varepsilon_i$	//$\eta_{\boldsymbol{W}}$は学習率, 重みW_i を更新
13.	$B_i \leftarrow B_i + \boldsymbol{noise}$	//ランダム行列にノイズを加える
14.	**end for**	

Statistics

図で使用したプロットにおいては、セッション間の平均値を実線で示し、±1 SD を影で図示した。~~SD なのか SE なのか。~~

乱数シードの設定方法

本研究では、複数回の独立試行を通じてモデル性能のばらつきを評価するため、乱数シードを session ごとに実質的に異なる値に設定した。具体的には、50 session 連続で実験を実施し、各 session において乱数シードを更新することで、重みの初期値および MNIST データセットのシャッフル順序が session 間で異なるようにした。この設定により、各 session は互いに独立な試行として扱われ、モデル性能の統計的評価が可能となる。

マクネマー検定

本研究では、提案手法である Dual Hebb モデルおよび LA モデルの分類性能が、baseline モデルと比較して統計的に有意な差を持つかを検証するため、マクネマー検定を用いた。マクネマー検定は、同一データセットに対する二つの分類器の予測結果の差を、対応のある二値データとして評価するための検定手法であり、同一入力サンプルに対する正誤の違いに着目した比較が可能である。

具体的には、テストデータに含まれる各サンプルについて、baseline モデルと比較対象モデル（Dual Hebb モデルまたは LA モデル）の分類結果をそれぞれ正解・不正解の二値として記録し、両モデルの予測が不一致となるサンプル数に基づいて 2×2 の分割表を構成した。そのうち、baseline モデルが正解で比較対象モデルが不正解であったサンプル数と、baseline モデルが不正解で比較対象モデルが正解であったサンプル数を用いて検定統計量を算出した。

検定は Dual Hebb モデルと baseline モデル、ならびに LA モデルと baseline モデルのそれぞれについて独立に実施し、有意水準は 5%（$p < 0.05$）とした。これにより、各提案モデルが baseline モデルと比較して分類性能に統計的に有意な差を示すかを評価した。

Commented [広兼浩二朗47]: これはどこで使ってる？？

Page 11: [1] Commented [広兼浩二朗 21R17] Kojiro Hirokane 2/23/26 9:49:00 PM

了解した。その代わり思ったんやけど、この Figure5B の図は”重みの初期値が十分無視できる”っていう前提条件を示すために実は LA と Dual hebb のところで必要な図なのでは？

本文でも初期値が無視できる限りにおいて転置になっていく、って主張しているわけやし。

だから、Figure 3D と Figure4C に初期値と比較した重みの cosine similarity を出して、十分初期力は離れていく＝初期値は無視できる。というふうに書くべきか。